

## Laporan Praktikum Minggu 2: Data Wrangling & EDA

Informasi Mahasiswa:

Nama: Muhammad Ikhwan Manshur

NIM: 2411070053

Link W&B Project: <https://wandb.ai/xxenonitee-stikomelrahma/titanic-eda-2026?nw=nwuserxxenonitee>

### 1. Pendahuluan

Tujuan praktikum ini adalah memahami proses pembersihan data (*data wrangling*) dan eksplorasi data (EDA) sebelum masuk ke tahap *modeling*. Mahasiswa belajar cara mengambil data dari cloud, mengidentifikasi masalah seperti *missing values*, melakukan *feature engineering*, serta menyimpan snapshot data agar eksperimen dapat direproduksi. Dataset Titanic digunakan karena memiliki kompleksitas yang pas untuk pemula, termasuk data teks, angka, dan banyak nilai yang hilang.

### 2. Analisis Data Mentah (Inspeksi)

Berdasarkan hasil `.info()` dan `.isnull().sum()`, kolom yang memiliki *missing values* adalah:

- **Age:** 177 data kosong.
- **Cabin:** 687 data kosong (lebih dari 70% data).
- **Embarked:** 2 data kosong.

### 3. Strategi Pembersihan Data

☒ **Imputasi Age:** Menggunakan **Median** karena lebih tahan terhadap pencilan (*outliers*) dibandingkan Mean.

☒ **Imputasi Embarked:** Menggunakan **Modus** (nilai tersering) karena datanya berbentuk kategori lokasi.

☒ **Penghapusan Cabin:** Kolom ini dihapus karena lebih dari 70% datanya kosong. Mengisinya secara paksa akan menciptakan banyak data palsu (*noise*) yang merusak model.

#### 4. Visualisasi & Temuan Utama

☒ **Survival Rate by Gender:** Wanita memiliki tingkat keselamatan lebih tinggi. Hal ini sesuai konteks historis "wanita dan anak-anak didahulukan" saat evakuasi.

☒ **Distribusi Umur:** Mayoritas penumpang berusia 20–40 tahun, dengan tren keselamatan yang bervariasi di tiap kelompok umur.

#### 5. Feature Engineering

☒ **Fitur FamilySize:** Rumus yang digunakan adalah:

$$FamilySize = SibSp + Parch + 1$$

☒ **Analisis:** Ukuran keluarga berpengaruh pada peluang selamat. Penumpang dengan keluarga kecil (2–4 orang) cenderung lebih selamat dibanding yang bepergian sendiri atau keluarga sangat besar.

☒ **Encoding:** Data teks seperti 'Sex' diubah menjadi angka (0/1) karena algoritma Machine Learning adalah kalkulator matematis yang hanya bisa memproses input numerik.

Encoding: Mengapa kita perlu mengubah data teks (seperti 'Sex') menjadi angka (0/1) sebelum masuk ke model Machine Learning?

#### 6. Integrasi Weights & Biases (W&B)

Di **W&B Tables**, saya bisa membandingkan `raw_data` dan `final_processed_data` secara interaktif. Fitur *filtering* membantu saya mencari penumpang spesifik tanpa kode tambahan, dan *sorting* membantu melihat korelasi antara harga tiket (*Fare*) dan keselamatan secara cepat dibandingkan hanya menggunakan `.head()`.

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Embarked	FamilySize
1	0	3	Brundage, Mr. Owen Harris	0	22	1	0	6151 21371	7.25	C	2
2	1	1	Cummings, Mrs. John Bradley	1	38	1	0	PC 17599	51.285	S	2
3	0	3	Heikkinen, Miss. Laina	0	26	0	0	STON/O2. 3101282	7.92	C	1
4	1	1	Futrelle, Mrs. Jacques	1	35	1	0	113803	53.1	C	2
5	0	3	Allen, Mr.	0	39	0	0	275408	8.05	C	1

## 7. Kesimpulan & Refleksi

Tantangan tersulit adalah memutuskan strategi imputasi yang paling tepat agar tidak merusak distribusi asli data. Kesimpulan utamanya adalah EDA sangat krusial; data yang kotor akan menghasilkan model yang buruk (*Garbage In, Garbage Out*). Instruksi Pengumpulan:

Isi template ini dengan lengkap.

Ekspor menjadi PDF atau simpan sebagai README.md di dalam folder tugas Anda.

Pastikan notebook .ipynb Anda sudah dijalankan hingga selesai (Run All) sebelum dikumpulkan.