Laporan Praktikum Minggu 3: Linear Regression & Regularization

Nama	: Siti Yolanda Hareniza
NIM	: 2411070032
Link W&B Project	: https://wandb.ai/sitiyolandahareniza-stikomelrahma/house-price-regression
Link Pull Request GitHub	: https://github.com/yolanland/Machine-Learning-Course-2026/tree/main/assignments/week-3/2411070032_Siti%20Yolanda%20Hareniza

1. Pendahuluan

Jelaskan secara singkat perbedaan utama antara Regresi Linear Standar, Ridge Regression (L2), dan Lasso Regression (L1). Mengapa kita membutuhkan teknik regularisasi saat melatih model Machine Learning?

Jawaban: Regresi Linear Standar adalah model yang digunakan untuk memprediksi nilai numerik dengan mencari bobot terbaik untuk setiap fitur tanpa adanya penalti. Model ini bisa bekerja dengan baik, tetapi jika fitur terlalu banyak, model bisa menjadi terlalu kompleks dan mengalami overfitting.

Ridge Regression (L2) menambahkan penalti berupa kuadrat dari bobot. Penalti ini membuat bobot menjadi lebih kecil sehingga model tidak terlalu bergantung pada satu fitur saja.

Lasso Regression (L1) menambahkan penalti berupa nilai absolut dari bobot. Berbeda dengan Ridge, Lasso bisa membuat beberapa bobot menjadi nol sehingga fitur yang tidak penting bisa otomatis dihilangkan.

Regularisasi dibutuhkan agar model tidak terlalu menyesuaikan diri dengan data training dan tetap bisa bekerja dengan baik pada data baru.

2. Pemahaman Dataset

Pada praktikum ini, kita menggunakan dataset **California Housing**.

Apa variabel target () yang ingin kita prediksi?

Mengapa kita perlu membuang kolom teks (`ocean_proximity`) dan baris yang kosong (`dropna`) sebelum memasukkannya ke dalam model Regresi Linear Scikit-Learn?

Jawaban: Variabel target yang ingin diprediksi adalah **median_house_value**, yaitu harga median rumah di California.

Kolom **ocean_proximity** perlu dibuang karena berisi teks, sedangkan model Regresi Linear hanya bisa memproses angka. Selain itu, baris yang memiliki nilai kosong dihapus **(dropna)** agar model tidak mengalami error saat proses training.

3. Hasil Baseline Model (Tanpa Hukuman)

Berdasarkan eksperimen pertama menggunakan `LinearRegression` biasa (tanpa regularisasi):

1. **Linear Regression**
   A. **RMSE:** 70,156.12
   B. **Score R^2**: 0.6401
2. **Ridge Regression (L2)**
   A. **RMSE :** 70,165.78
   B. **Score R^2 :** 0.6400
3. **Lasso Regression (L1)**
   A. **RMSE :** 70,159.23
   B. **Score R^2 :** 0.6401

Interpretasi: Apa arti dari nilai RMSE tersebut dalam konteks harga rumah di California?

Jawaban: Nilai RMSE menunjukkan rata-rata kesalahan prediksi model terhadap harga rumah sebenarnya dengan hasil RMSE sekitar 70.000 atau $70.000. Semakin kecil RMSE, maka semakin baik model dalam memprediksi harga rumah. Nilai R^2 menunjukkan seberapa besar variasi harga rumah yang dapat dijelaskan oleh model.

4. Eksperimen Regularisasi "The Power of Alpha" (Tugas Inti)

Isi tabel di bawah ini berdasarkan hasil eksperimen Anda saat mengubah nilai parameter `alpha` pada model Ridge dan Lasso.

Model	Alpha ()	RMSE	Score	Catatan Visualisasi Bobot (Blok 5)
Ridge	0.1	70156.13	0.6401	Bobot masih sangat mirip dengan Linear, hampir tidak ada perubahan signifikan
Ridge	100	70165.78	0.6400	Bobot mulai mengecil, tetapi masih mempertahankan semua fitur

Ridge	1000	70429.88	0.6373	Bobot semakin menciut mendekati nol, model menjadi lebih sederhana
Lasso	0.1	70156.12	0.6401	Bobot masih mirip dengan Linear, belum ada fitur yang menjadi nol
Lasso	100	70159.23	0.6401	Beberapa bobot mulai mengecil signifikan
Lasso	1000	70230.12	0.6393	Beberapa fitur menjadi tepat nol (tereliminasi)

Analisis Hasil Eksperimen:

1. Apa yang terjadi pada nilai RMSE jika nilai `alpha` dibuat terlalu besar (misal 1000)? Apakah model menjadi lebih pintar atau justru mengalami *Underfitting*?

2. Berdasarkan grafik visualisasi bobot, algoritma mana (Ridge atau Lasso) yang secara agresif membuang fitur hingga nilai bobotnya tepat nol?

Jawaban:

1. Ketika nilai alpha dibuat terlalu besar (1000), nilai RMSE meningkat dan nilai R^2 menurun. Hal ini menunjukkan bahwa model menjadi terlalu sederhana karena penalti terhadap bobot terlalu besar. Akibatnya, model tidak mampu menangkap pola data dengan baik dan mengalami underfitting. Pada hasil eksperimen terlihat bahwa RMSE pada alpha 1000 lebih besar dibandingkan alpha 0.1, yang berarti performa model menurun.
2. Berdasarkan karakteristik regularisasi, Lasso (L1) lebih agresif dalam membuang fitur karena dapat membuat nilai bobot menjadi tepat nol. Sedangkan Ridge (L2) hanya mengecilkan bobot tetapi tidak sampai nol.

5. Dokumentasi Weights & Biases (W&B)

Lampirkan *screenshot* dari *dashboard* W&B Anda. Karena Anda melakukan banyak eksperimen dengan berbagai nilai `alpha`, panel W&B Anda sekarang seharusnya menampilkan banyak titik eksperimen untuk metrik RMSE dan .

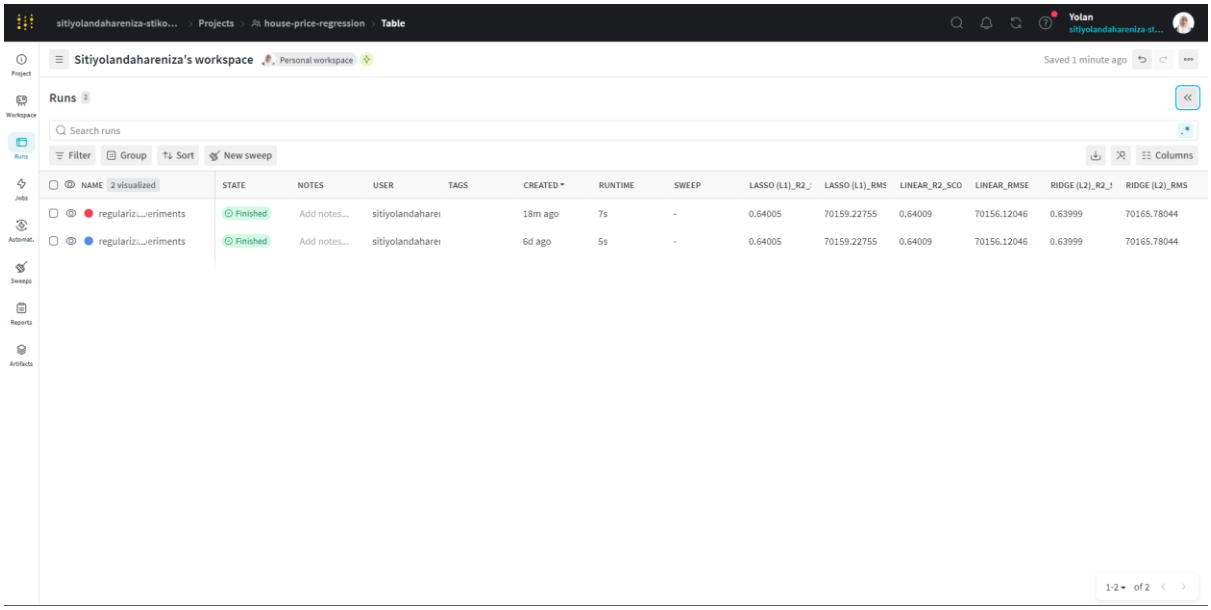

Gambar 1. Detail nilai dari eksperimen nilai ‘alpha’

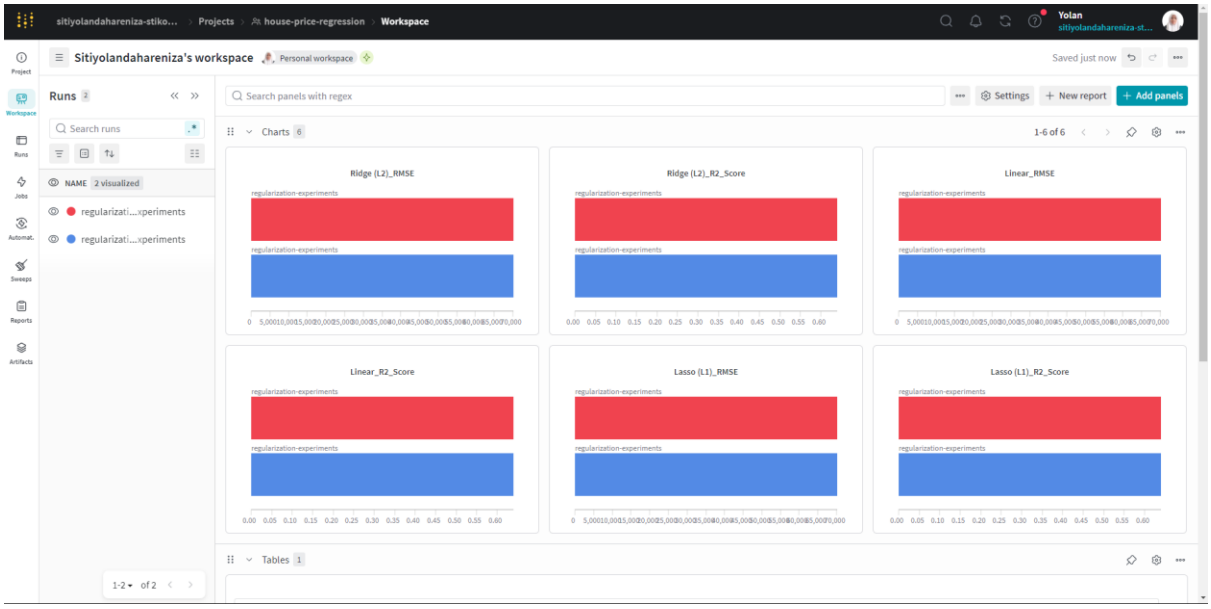

Gambar 2. Dashboard W&B eksperimen nilai ‘alpha’

6. Kesimpulan & Refleksi

Dari seluruh eksperimen di atas, model dengan pengaturan parameter apa yang menghasilkan performa terbaik (RMSE terendah dan tertinggi)?

Apa tantangan terbesar Anda saat mengerjakan praktikum minggu ini?

Jawaban: Model dengan performa terbaik diperoleh pada nilai alpha = 0.1, baik pada Ridge maupun Lasso, karena menghasilkan nilai RMSE paling rendah dan R^2 paling tinggi dibandingkan pengaturan alpha lainnya. Ketika nilai alpha diperbesar hingga 1000, nilai RMSE meningkat dan R^2 menurun. Hal ini menunjukkan bahwa regularisasi yang terlalu kuat membuat model menjadi terlalu sederhana dan mengalami underfitting. Oleh karena itu, pemilihan nilai alpha yang tepat sangat penting agar model tetap seimbang antara kompleksitas dan kemampuan generalisasi.

Tantangan terbesar dalam praktikum ini adalah memahami pengaruh parameter nilai alpha pada perubahan performa model serta menginterpretasikan perbedaan antara Ridge dan Lasso hingga perlu memahaminya lebih lanjut dengan membaca pengertiannya berulang kali.