Laporan Praktikum Minggu 3: Linear Regression & Regularization

Nama : Raki Raihan

NIM : 2411070095

Link W&B Project : https://wandb.ai/han-dev321-stikomelrahma/house-price-regression/workspace?nw=nwuserhandev321

Link Pull Request GitHub : https://github.com/slr549/Machine-Learning-Course-2026

---

1. Pendahuluan

- **Perbedaan utama antara**

Fitur	Regresi Linear standar	Ridge Regression (L2)	Lasso Regression (L1)
Fungsi Penalti	Penalti tidak ada	Menambah kuadrat dari koefisien ($\lambda \sum w^2$)	Menambah nilai absplut dari koefisien ($\lambda \sum
Tujuan Utama	Min.error pada data latihan	Mengercilkan nilai koefisien agar dekat nol	Bisa mengecilkan koefisien **hingga menjadi nol**
Kapan Digunakan	data sederhana dan tidak ada korelasi	Ketika semua fitur hampir memiliki pengaruh, tapi ingin mencegah overfitting	Ketika ingin melakukan **seleksi fitur**
Efek Pada Modal	Sangat sensitive pada outlier dan data kompleks	Menjadi lebih stabil pada variasi data yang tinggi	Lebih "ramping" (*Sparse*), karena fitur tidak relevan

- **Mengapa membutuhkan teknik regulasi :** Karena saat kita melatih model ML, seringkali dihadapi dengan model terlalu "pintar" dalam menghafal data latihan hingga gagal memprediksi data baru (**Overfitting**). Maka disini fungsinya regulasi hadir yaitu sebagai **penjaga** yang memberikan **peringatan** pada koefisiensi model agar model tetap sederhana, tidak terlalu kompleks, dan mampu generalisasi yang lebih baik pada data yang belum pernah diliat sebelumnya

---

2. Pemahaman Dataset

- Kita inggin prediksi variabel target (“**median_house_value**”) “variabel dependen (label)”
- Membuang kolom teks (“**ocean_proximity**”) dan baris kosong (“**dropna”**):
    - **Ocean_proximity :**

      Dikarenakan algoritma **Linear Regression** di Scikit-Learn merupakan model yang bekerja dengan matriks angka dengan rumus “**$$Y = \beta_0 + \beta_1X_1 + \beta_2X_2 + ... + \epsilon$$**”.

      - **Masalahnya :** Fitur ocean_proximity berisi data teks/kategorikal (“NEAR BAY”,“<1H OCEAN”).
      - **Alasan :** dikarenakan computer tidak bisa melakukan operasi matematika terhadap teks.
    - **Dropna :**

      di dalam matematika, data yang hilang atau NaN (Not a Number) dianggap sebagai nilai yang tidak terdefinisi.

      - **Masalahnya :** apabila computer mencoba melakukan perhitungan dan bertemu dengan nilai kosong, maka *output* akhirnya akan **kosong** atau **error.**
      - **Alasan :** Algoritma Scikit-Learn memerlukan matriks input yang lengkap dan solid. Dropna = satpam “memastikan bahwa setiap baris dara yang masuk ke model memiliki nilai lengkap, sehingga perhitungan statistic model menjadi valid dan tidak terdistorsi”.

---

3. Hasil Baseline Model (Tanpa Hukuman)

Linear Regression biasa (tanpa regularisasi)

- **RMSE :** $70,156.12
- **Score :** 0.64
- **Interpretasi :** RMSE (**Root Mean Square Error**) adalah rata-rata besarnya kesalahan (error) model dalam memprediksi harga rumah

---

4. Eksperimen Regularisasi “The Power of Alpha” (Tugas Inti)

Model	Alpha ()	RMSE	Score	Catatan Visualisasi Bobot (Blok 5)
Ridge	0.1	70156.12713	0.64	Bobot masih mirip dengan linear
Ridge	100	70165.78044	0.64	Semua bobot mendekati nol, tapi fitur median_income tertinggi dari yang lain
Ridge	1000	70429.87849	0.637	Hanya ada perbedaan di fitur longitude dan latitude: lebih tinggi dari lasso
Lasso	0.1	70156.12309	0.64	Bobot masih mirip dengan linear

Lasso	100	70159.22755	0.64	Semua bobot mendekati nol, tapi fitur median_income tertinggi dari yang lain
Lasso	1000	70230.12332	0.639	Hanya ada perbedaan di fitur longitude dan latitude: lebih rendah dari ridge

Analisis Hasil :

1. **Jika RMSE "alpha (1000)" :** maka model mengalami **Underfitting,** karena penalty yang terlalu berat terhadap koefisien fitur, sehingga jadi terlalu sederhana dan kaku
2. **Algoritma mana yang agrefsif membuang fitur hinggal nilai nol bobotnya :**
    a. **Lasso :** berfungsi sebagai alat seleksi fitur otomatis.
    b. **Ridge :** hanya akan mengecilkan nilai koefisien (shrinkage) agar mendekati nol.

---

5. Dokumentasi Weights & Biase

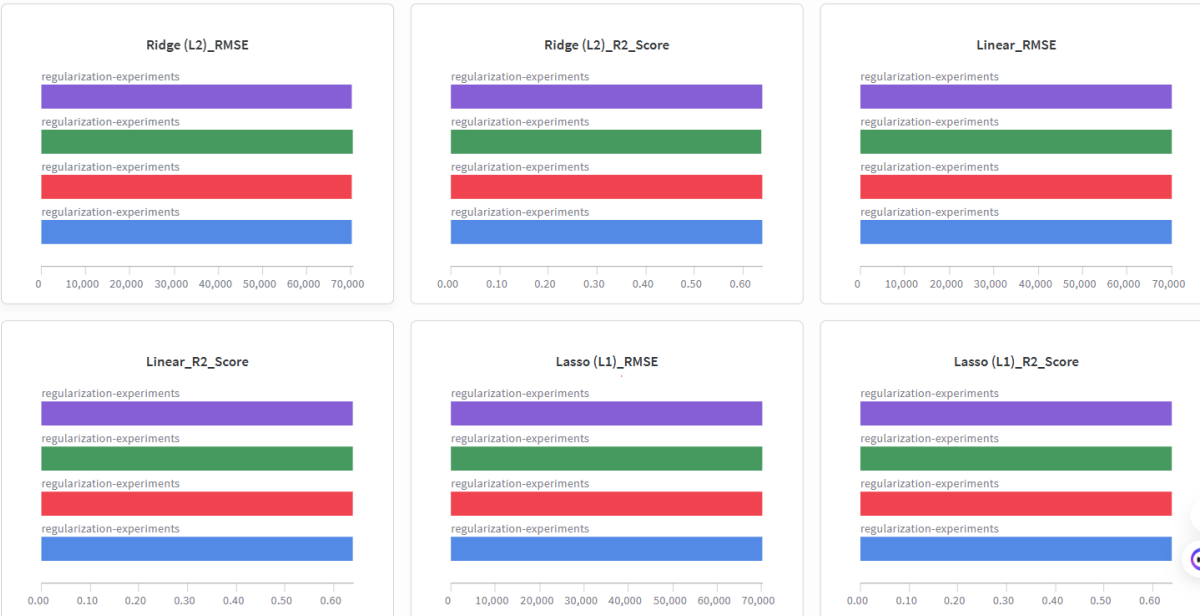

---

6. Kesimpulan & Refleksi

1. Analisis Model Terbaik Dan Terburuk

1. RMSE Terendah : Performa terbaik dihasilkan oleh model **Ridge dengan a = 0.1,** yang mencatat nilai terkecil sebesar **70156.12713.** dikarenakan model mampu menyeimbangkan kompleksitas data tanpa kehilangan akurasi prediksi secara signifikan.

2. RMSE Tertinggi : Performa terbaik dihasilkan oleh model **Ridge dengan a = 1000,** yang mencatat nilai terkecil sebesar **70429.87849.** dikarenakan parameter a yang besar memaksa model manjadi kaku